LeiKo: Koreferenzannotation

Sarah Jablotschkin

Stand: 15. März 2022

Die vorliegenden Guidelines wurden für die Annotation von Koreferenz in LeiKo (Jablotschkin/Zinsmeister 2020) erstellt. Sie bauen auf den Guidelines von Naumann (2007), Reznicek (2013) sowie Chiarcos et al. (2016) auf, wurden aber an einigen Stellen modifiziert bzw. ergänzt, um die Annotation von bestimmten Koreferenzphänomenen in Leichter und einfacher Sprache zu ermöglichen. Die Texte wurden automatisch vorannotiert mit dem Tool von Schröder et al. (2021) und anschließend mit dem CorefAnnotator von Reiter (2018) manuell korrigiert.

Inhaltsverzeichnis

1 Markables	2
2 Ersetzungstest für Koreferenz	
3 Beispiele für Koreferenz	4
4 Metonymie	
5 Generische Referenz	5
6 Bestimmte Konstruktionen und Phänomene	
6.1 Kopula-Konstruktionen/prädikative NPs	6
6.2 Gruppenreferenz	
6.3 Bezugnahme auf die sprachliche Oberfläche	7
6.4 Indefinite NPs	7
6.5 Satzfragmente	7
6.6 Reflexive Verben	7
6.7 Adverbien und Partikeln	8
6.8 Untypische Verwendung von Definitartikeln und Demonstrativpronomina	8
7 Umsetzung der Annotation im CorefAnnotator (Reiter 2018)	8
7.1 Annotation von Gruppen:	8
7.2 Relativsätze	9
Referenzen	9

1 Markables

Vgl. Naumann (2007: 3/4)

- Die folgenden Ausdrücke sind potentielle Markables:
 - x definite NPs (inkl. Eigennamen)
 - x abweichend von Naumann (2007): indefinite NPs
 - x abweichend von Naumann (2007): Köpfe von generisch referierenden indefiniten Plural-NPs
 - x Personalpronomen
 - x Relativpronomen
 - x Reflexivpronomen (sich)
 - x Reziprokpronomen
 - x Demonstrativpronomen
 - x Indefinitpronomen (man)
 - x Possessivpronomen
- Nur diejenigen potentiellen Markables, die einen nominalen Bezugsausdruck haben, werden annotiert. D.h., wenn ein potentielles Markable auf einen nicht-nominalen Ausdruck referiert, wird es nicht annotiert.
- Es werden keine Singletons annotiert.
- Markables können im Haupttext, aber auch in Überschriften stehen. Es werden auch Relationen zwischen Überschriften und Haupttext hergestellt.
- Grenzen des Markables sind definiert durch die maximale Ausdehnung der NP¹, das heißt, Komplemente und Adjunkte des Kopfnomens werden miteinbezogen, ebenso Appositionen in Klammern, zwischen Kommata und Gedankenstrichen. Auch koordinierte NPs können ein Markable darstellen. Sowohl die Koordination als Ganzes als auch die einzelnen Konjunkte können als Markables annotiert werden.
- · Markables können in andere Markables eingebettet sein.

In LeiKo annotieren wir auch Koreferenz **generisch verwendeter Ausdrücke**. Daraus ergeben sich die folgenden Regelungen in Bezug auf die Identifikation von Markables:

• Wenn ein Markable nur mit einem Teil einer komplexen NP koreferent ist (z.B. weil generisch referiert wird und der wiederaufnehmende generische Ausdruck durch ein Mengenattribut modifiziert ist), kann auch ein Teil der komplexen NP als Markable annotiert werden. In (1) wird in der NP immer mehr widerstandsfähige Keime die AdjP immer mehr nicht als Teil des Markables annotiert. In der NP große Mengen Antibiotika wird nur Antibiotika als Markable annotiert. Begründet werden kann dies mit dem Ersetzungstest. Immer mehr widerstandsfähige Keime kann ersetzt werden durch immer mehr davon, große Mengen Antibiotika durch große Mengen davon. Nur der pronominalisierbare Teil wird jeweils als Markable annotiert. Vgl. auch Beispiel (2). Wird

¹ Ausnahmen: Relativsätze und generische indefinite Plural-NPs

- aber auf die Gesamtklasse im Text gar nicht referiert, kann auch die modifizierte generische NP als Markable annotiert werden.
- Wird eine NP durch das Indefinitpronomen *kein* modifiziert, kann der Satz umgeformt und mit *nicht* negiert werden. Durch die Satznegation kann das zu annotierende Markable identifiziert werden. Z.B. kann in Beispiel (3) *dass wir keine Eier zum Leben brauchen* umgeformt werden in *dass wir Eier/sie nicht zum Leben brauchen*.
 - (1) [Die Keime] sind widerstandsfähig gegen [Antibiotika]. Warum gibt es immer mehr [widerstandsfähige Keime]? Warum wirken [die Antibiotika] nicht? Ein Grund dafür ist: Deutsche Ärzte verschreiben große Mengen [Antibiotika] an kranke Menschen.
 - (2) Die Regierung im Land Großbritannien will verhindern, dass Menschen durch [Zucker] krank werden. [...] Aber auch in Deutschland essen und trinken die Menschen zu viel [Zucker].
 - (3) In vielen Lebensmitteln sind [Eier]. [...] Wo kommen [diese Eier] her? Sie kommen meistens von Hühnern auf sehr großen Bauernhöfen. [...] Bei der Aktion zeigt "Peta":
 - dass wir keine [Eier] zum Leben brauchen
 - und wodurch wir [Eier in Lebensmitteln] ersetzen können.

" Peta " sagt: Wenn die Menschen keine **[Eier]** mehr essen, dann werden dafür keine Hühner mehr gequält .

2 Ersetzungstest für Koreferenz

"Ob ein referentieller Ausdruck e zu einer Kette k gehört, kann mit einem Ersetzungstest geprüft werden […]: Wenn für jedes Substantiv s (Nomen, Eigenname) in k gilt, dass die Ersetzung von e durch s die Interpretation des Textes nicht verändert, so gehört e zur Kette k und es ist eine Koreferenz-Relation […] zu annotieren." (Chiarcos et al. 2016: 72) "Es gelten zwei gegebene nominale Beschreibungen als koreferent, wenn es möglich ist, sie untereinander durch die jeweils andere zu ersetzen. (Dabei können gewisse Umformungen nötig sein, etwa die Entfernung von Präpositionen aus Markables.)" (Chiarcos et al. 2016: 78)

- In (1) können die Keime und widerstandsfähige Keime einander ersetzen (vgl. (4) und (5)). Große Mengen Antibiotika kann nicht Antibiotika ersetzen (vgl. (6)). Der Ersetzungstest funktioniert aber nicht, wenn mit dem gleichen Ausdruck abwechselnd auf eine spezifische Entität und eine Klasse referiert wird. Dieses Phänomen tritt insbesondere bei den in Leichter und einfacher Sprache häufigen Worterklärungen auf (vgl. Beispiele (14)-(16)). Der Ersetzungstest ist ebenfalls kein Zeichen für Koreferenz, wenn auf die sprachliche Oberfläche Bezug genommen wird und nicht auf den außersprachlichen Referenten (vgl. Beispiel (20)).
 - (4) Widerstandsfähige Keime sind widerstandsfähig gegen Antibiotika. Warum gibt es immer mehr widerstandsfähige Keime?
 - (5) Die Keime sind widerstandsfähig gegen Antibiotika. Warum gibt es immer mehr dieser Keime/davon?

(6) *Warum wirken die großen Mengen Antibiotika nicht? Ein Grund dafür ist: Deutsche Ärzte verschreiben große Mengen Antibiotika an kranke Menschen.

3 Beispiele für Koreferenz

Wir annotieren Referenzketten der Typen (7)-(11) nach Naumann (2007). Die Relationstypen selbst annotieren wir allerdings nicht. Die Kategorien unter den Beispielen sind nur zum besseren Verständnis und zum einfacheren Nachschlagen in den Guidelines angegeben.

Für (7)-(9) eignet sich der Ersetzungstest für Koreferenz nach Chiarcos et al. (2016; s.o.) (außer es handelt sich bei dem Markable um ein Reflexivpronomen).

Für (11) funktioniert der Ersetzungstest nur in eine Richtung: Der Plural-Ausdruck kann durch die miteinander koordinierten Einzel-NPs ersetzt werden.

(7) Der Vorhang geht wieder auf im [Metropol]. Kultursenator will [das Theater] an Privatinvestor verkaufen. (Naumann 2007: 12)

<u>Kategorie</u>: Coreferential (zwei definite (nicht-anaphorische) NPs verweisen auf denselben außersprachlichen Referenten)

Ersetzungstest: anwendbar

(8) Ein klarer [Ton] breitet [sich] aus, warm und satt, bis [er] den ganzen Saal erfüllt.

Dann dünnt [er] aus, zerbröselt und verflüchtigt [sich]. (Naumann 2007: 17)

<u>Kategorie</u>: Anaphoric (Pronomen verweisen zurück auf einen bereits eingeführten Referenten)

Ersetzungstest: anwendbar

(9) "Sollen sie [mich] als Narren ansehen!" [Ulrich Görlitz] diente freiwillig in Hitlers Armee. (Naumann 2007: 21)

<u>Kategorie</u>: Cataphoric (ein Pronomen verweist auf ein Antezedens, das erst im Darauffolgenden eingeführt wird)

Ersetzungstest: anwendbar

(10) [Wer] einen Sitzplatz haben will, [der] muss um 19 Uhr [...] da sein. (Naumann 2007: 23)

<u>Kategorie</u>: Bound (ein definites Pronomen (hier: *der*) hat eine indefinite NP als Antezedens (hier: *wer*); die Referenz des Antezedenten lässt sich aber nicht bestimmen, vgl. auch Reznicek 2013: 6)

Ersetzungstest: nicht anwendbar

(11) "Vor allem die letzten Stunden waren fürchterlich", sagt [eine junge Frau], die [ihre gebrechliche Mutter und vier Kinder] über die Grenze führt. [Sie] sind zu Fuß gekommen, denn das Auto wurde [ihnen] von serbischen Freischärlern abgenommen. (Naumann 2007: 29)

<u>Kategorie</u>: Split_antecedent (ein Plural-Pronomen bzw. eine koordinierte NP referiert auf eine Gruppe, deren Mitglieder außerdem mithilfe weiterer NPs einzeln wiederaufgenommen werden)

Ersetzungstest: eingeschränkt anwendbar (Gruppen-Ausdruck kann durch Ausdrücke der Einzelentitäten ersetzt werden)

(12) [Schlager] sind deutsche Lieder. [Viele von [den Schlagern]] sind schon alt.

In diesem Beispiel wird durch Schlager ein Referent etabliert. Durch viele von den Schlagern wird eine Instanz dieses Referenten wiederaufgenommen, was nach den Guidelines der TüBa-D/Z eine Instance-Relation darstellt. Wir annotieren viele von den Schlagern hier aber nicht als koreferent mit Schlager, weil wir bereits die Koreferenz zwischen Schlager und den Schlagern herstellen. Referenzketten des Typs Instance (vgl. Naumann 2007: 31-34) annotieren wir nicht.

4 Metonymie

Metonymie ist laut den TüBa-D/Z-Guidelines eine rein semantische Relation und wird nicht annotiert (Naumann 2007: 2). Auch NoSta-D richtet sich nach dieser Konvention (Reznicek 2013: 5). In Bsp. (13) besteht Metonymie zwischen *viele wichtige Politiker* und *die Länder*, weil *die Länder* stellvertretend für die Politiker verwendet wird, die das jeweilige Land regieren bzw. entscheidungsbefugt in Bezug auf Nato-Einsätze sind. (Ein Land ist keine Person und kann daher genaugenommen keine Einsätze machen.)

(13) Viele wichtige Politiker aus der ganzen Welt sind bei dem Treffen von der Nato gewesen. [...] Die Länder machen zum Beispiel gemeinsame Einsätze mit ihren Soldaten.

5 Generische Referenz

Wir annotieren auch Koreferenz generischer Ausdrücke (kein Bezug auf einen bestimmten Referenten, sondern auf eine Klasse). Insbesondere bei Worterklärungen (im Originaltext tlw. typographisch abgehoben durch Einrückung, vgl. Bsp. (14)) muss geprüft werden, ob eine Referenzkette zum Haupttext besteht oder ob die Referenzkette sich nur über den Textteil mit der Erklärung/in der Einrückung bezieht. Im Zweifel werden zwei separate Referenzketten annotiert. In Bsp. (15) ist es durch den rekurrenten Ausdruck diese Arbeit schwer zu entscheiden, welche Mentions zu ein und derselben Referenzkette gehören. Der Ersetzungstest deutet aber darauf hin, dass es sich beim letzten diese Arbeit um eine Wiederaufnahme des Ehrenamts im Saarland handelt (diese Arbeit kann durch das Ehrenamt im Saarland ersetzt werden). Teilweise wird ein und derselbe Ausdruck abwechselnd für die generische Referenz auf ein auf ein regelmäßig wiederkehrendes Ereignis insgesamt und die Referenz auf ein spezifisches Auftreten dieses Ereignisses verwendet. In (16) wird mit die Olympischen Spiele zunächst generisch auf das wiederkehrende Ereignis referiert und im Anschluss auf die diesjährigen Olympischen Spiele.

```
(14) In Nordrhein-Westfalen war [ein Prozess].
[Ein Prozess] ist ein Streit vor Gericht.
Bei [einem Prozess] entscheidet das Gericht [...]
```

[Der Prozess] war in Paderborn.

(15) Die Gemeinschaft Pro Ehrenamt will dazu eine Seite im Internet einrichten.

Die Gemeinschaft Pro Ehren amt will [das Ehren amt im Saarland] fördern. [Ehren amt] heißt:

Menschen arbeiten zum Beispiel freiwillig

- im Krankenhaus
- in der Kirche
- bei Hilfsorganisationen.

Für [diese Arbeit] bekommen die Menschen aber kein Geld.

Die Gemeinschaft Pro Ehren amt möchte [diese Arbeit] besser organisieren.

(16) [Die Olympischen Spiele] sind immer in einem anderen Land.

In diesem Jahr sind [die Olympischen Spiele] in Süd·korea.

[...]

Bei [den Olympischen Spielen] sind auch 5 Sportler aus Nord-deutschland.

6 Bestimmte Konstruktionen und Phänomene

6.1 Kopula-Konstruktionen/prädikative NPs

Standardmäßig wird Koreferenz zwischen den Ausdrücken einer Prädikation nicht annotiert. Dabei gibt es zwei Ausnahmen:

- Das Prädikativum ist definit (vgl. Naumann 2007: 12).
 (17) [Kurz] ist [der Kanzler von dem Land Österreich]. (nachrichtenleicht)
- Abweichend von Naumann 2007: Die Prädikation wird dazu genutzt, um eine Gruppenentität explizit in seine Einzelentitäten aufzugliedern, um diese im Folgenden wieder aufgreifen zu können. In Bsp. (18) besteht eine Gruppenreferenz (vgl. (11)) von ein Musikfest und eine Sportveranstaltung zu diese zwei großen Veranstaltungen. Gleichzeitig besteht eine Koreferenzrelation zwischen diese zwei großen Veranstaltungen und die zwei großen Veranstaltungen. Das erste Mention diese zwei großen Veranstaltungen erhält daher drei Farben (bzw. drei Indizes): Eine für die Entität Musikfest, eine für die Entität Sportveranstaltung und eine für die Gruppenentität zwei große Veranstaltungen.
 - (18) [Diese zwei großen Veranstaltungen] sind: [Ein Musik-fest]. Und [eine Sport-veranstaltung]. [Die zwei großen Veranstaltungen] sind in St. Pauli.

6.2 Gruppenreferenz

Wenn ein Markable im Plural im Text auch in Form seiner Einzelentitäten auftritt, wird von den Markables der Einzelentitäten zum Pluralmarkable jeweils eine Koreferenzrelation annotiert. Das Pluralmarkable erhält dann alle Farben/Indizes der Einzelentitäten, auf die es referiert (vgl. Bsp. (19)). Wird das Pluralmarkable selbst im Text auch als Gruppe wiederaufgenommen, erhält es eine weitere Farbe/einen weiteren Index für die Koreferenzrelation zwischen den Gruppenmarkables (vgl. Bsp. (18)). Tritt die Gruppentität mehrfach im Text auf, wird die Koreferenz der Einzelentitäten immer zum Pluralmarkable annotiert, das die geringste Distanz zu einer der Einzelentitäten hat. Beide Einzelentitäten

sollen mit demselben Gruppenausdruck verbunden werden (auch dann, wenn eine Einzelentität der einen Erwähnung der Gruppe am nächsten ist und die andere Einzelentität der anderen Erwähnung der Gruppe).

- (19) [Diese Parteien] wollen den Paragraphen abschaffen:
 - [Bündnis 90/Die Grünen]
 - [Die Linke]
 - [SPD]

6.3 Bezugnahme auf die sprachliche Oberfläche

Manchmal wird mit dem gleichen Ausdruck mal auf den außersprachlichen Referenten und mal auf die sprachliche Oberfläche Bezug genommen. In diesem Fall werden die Ausdrücke nicht als koreferent annotiert, auch wenn sie auf der Oberfläche identisch sind. In Beispiel (20) wird mit der zweiten Erwähnung von *Spaceship* lediglich auf die sprachliche Oberfläche Bezug genommen, nicht auf den Referenten an sich.

(20) Dort findet ab und zu [eine inklusive Party] statt. [Die Party] heißt: [Spaceship]. Spaceship spricht man so aus: Speys-Schipp.

6.4 Indefinite NPs

Laut den TüBa-D/Z-Guidelines (Naumann 2007: 4) werden **indefinite Nominalphrasen** nur als Antezedenten annotiert (d.h., zwischen zwei indefiniten NPs wird keine Relation hergestellt). Wir richten uns in diesem Fall aber nach den NoSta-D-Guidelines. Sofern "die Zuordnung aus dem Kontext möglich ist", annotieren wir auch Koreferenz zwischen indefiniten NPs (Reznicek 2013: 5).

6.5 Satzfragmente

Manchmal ist in Fragmenten die maximale Ausdehnung einer NP nicht eindeutig zu bestimmen. Wir richten uns hier nach der bereits vorgenommenen Dependenzannotation (vgl. Foth 2006). In Fragmenten ohne Verb werden beispielsweise NPs und PPs nicht aneinander, sondern jeweils an den Wurzelknoten angebunden. Demnach sind in der Überschrift in Beispiel (21) die maximalen NPs *2 große Veranstaltungen* und *Hamburg*.

(21) [2 große Veranstaltungen] in [Hamburg]

6.6 Reflexive Verben

Bei inhärent reflexiven Verben stellt das Pronomen *sich* kein Markable dar. Ein Indiz dafür, ob ein Verb inhärent reflexiv ist, kann der Koordinationstest liefern. In (22) ist *sich* koreferent mit *Annalena Baerbock*. In (24) jedoch stellt *sich* kein Markable dar.

- (22) [Annalena Baerbock] will [sich] für den Klima-Schutz einsetzen.
- (23) [Annalena Baerbock] will [sich] und all ihre Energie für den Klima-Schutz einsetzen.
- (24) Grenell soll sich nicht in deutsche Politik einmischen.
- (25) *Grenell soll sich und seine Meinung nicht in deutsche Politik einmischen.

6.7 Adverbien und Partikeln

Die Adverbien *selbst* und *auch* werden nicht in die Ausdehnung der Markables inkludiert, auch wenn z.B. der Vorfeldtest darauf hindeutet.

- (26) [Gauland] selbst hat gesagt: [...]
- (27) Auch [Bundes-Kanzlerin Angela Merkel] war dabei.

6.8 Untypische Verwendung von Definitartikeln und Demonstrativpronomina

Der Einsatz von Nominalphrasen mit definitem Artikel oder Demonstrativpronomen ist teilweise untypisch und gibt nur bedingt Hinweise auf die Koreferenz mit anderen referierenden Ausdrücken. In Zweifelsfällen hat der Ersetzungstest immer Vorrang. In Beispiel (28) gibt es u.a. die generische Entität *Keime* und die Entität *widerstandsfähige Keime*. Das Demonstrativpronomen in der NP *diese Keime* (siehe letzter Satz) suggeriert, dass auf die Erwähnung von *die Keime* unmittelbar davor Bezug genommen wird. Allerdings spricht der Ersetzungstest dagegen: *Diese Keime* kann durch *widerstandsfähige Keime* ersetzt werden, alle andere Erwähnungen von *Keime* hingegen nicht. Mit *diese Keime* wird Bezug genommen auf das am Anfang des Textausschnitts stehende *widerstandsfähige Keime*. *Die Keime* wiederum scheint eine generische Referenz zu sein, obwohl sie mit definitem Artikel verwendet wird.

(28) Warum gibt es immer mehr [widerstandsfähige Keime]? [...] Ein Grund dafür ist: Deutsche Ärzte verschreiben große Mengen Antibiotika an kranke Menschen. [Die Keime] sind deshalb immer öfter Antibiotika ausgesetzt. [Die Keime] gewöhnen sich an diese Antibiotika. Und [die Keime] entwickeln Abwehr-Kräfte gegen diese Antibiotika. Die Folge davon ist: Antibiotika helfen nicht mehr gegen [diese Keime].

7 Umsetzung der Annotation im CorefAnnotator (Reiter 2018)

7.1 Annotation von Gruppen:

Der CorefAnnotator erlaubt das Zusammenfassen verschiedener Referenten zu Gruppen. Diese Funktion nutzen wir **nicht**². Stattdessen annotieren wir den Gruppenausdruck als koreferent mit beiden Einzelausdrücken. In Bsp. (29) wird *die beiden* sowohl der Entität *Donald Trump* als auch der Entität *Angela Merkel* hinzugefügt. Vgl. auch Bsp. (18) weiter oben.

(29) Zum Beispiel [der Präsident von den USA, Donald Trump] Auch [Bundes-Kanzlerin Angela Merkel] war dabei. [Die beiden] hatten Streit.

² In der ConLL-Datei erhält "die beiden" sonst einen eigenen Index. Das Ziel ist aber, dass es die Indizes beider Antezedenten erhält. Das geht nur, wenn man es in den Farben für Donald Trump und Angela Merkel markiert.

7.2 Relativsätze

Die durch den Relativsatz modifizierte NP und das Relativpronomen werden als zwei separate Markables derselben Referenzkette annotiert. Der Relativsatz selbst wird nicht markiert (vgl. (30)).

(30) In Deutschland sind große Partei-Spenden verboten, wenn sie aus [Ländern] kommen, [die] nicht zu der Europäischen Union gehören.

Referenzen

Chiarcos, Christian / Stede, Manfred / Warzecha, Saskia (2016): Nominale Koreferenz. In: Stede, Manfred (Hrsg.): Handbuch Textannotation. Potsdamer Kommentarkorpus 2.0. Potsdam: Universitätsverlag. 71-87. URL:

https://publishup.uni-potsdam.de/opus4-ubp/frontdoor/deliver/index/docId/8276/file/pcss8.pdf.

Foth, Kilian (2006): Eine umfassende Constraint-Dependenz-Grammatik des Deutschen. Hamburg. http://edoc.sub.uni-hamburg.de/informatik/volltexte/2014/204/.

Jablotschkin, Sarah / Zinsmeister, Heike (2020): LeiKo: A corpus of easy-to-read German. Poster presentation at the Computational Linguistics Poster Session in the course of the 42nd annual conference of the Deutsche Gesellschaft für Sprachwissenschaft (DGfS), Hamburg. DOI: 10.5281/zenodo.3626763

Naumann, Karin (2007): Manual for the Annotation of in-document Referential Relations. Seminar für Sprachwissenschaft, Abt. Computerlinguistik Universität Tübingen. URL: https://www.sfs.uni-tuebingen.de/fileadmin/static/ascl/resources/tuebadz-coreference-manual-2007.pdf

Reiter, Nils (2018): CorefAnnotator - A New Annotation Tool for Entity References. In Abstracts of EADH: Data in the Digital Humanities. DOI: 10.18419/opus-10144

Reznicek, Mark (2013): Linguistische Annotation von Nichtstandardvarietäten – Guidelines und "Best Practices". Guidelines Koreferenz. Version 1.1. Angewandte Sprachwissenschaft, Computerlinguistik Ruhr-Universität Bochum. URL: https://www.linguistik.hu-berlin.de/de/institut/professuren/korpuslinguistik/forschung/nosta-d/nosta-d-cor-1.1

Schröder, Fynn / Hatzel, Hans Ole / Biemann, Chris (2021): Neural End-to-end Coreference Resolution for German in Different Domains. In: *Proceedings of the 17th Conference on Natural Language Processing (KONVENS 2021).* 170–81. Düsseldorf: KONVENS 2021 Organizers. URL: https://aclanthology.org/2021.konvens-1.15/